

9-я FLOPs

Рассчитаем количество операций:

$$MACs = H \times W \times C_{in} \times C_{out} \times k^2 \Rightarrow FLOPs = 2 \times H_{out} \times W_{out} \times C_{in} \times C_{out} \times k^2$$

$$FLOPs(Convl 7 \times 7, S_2) = 2 \times H_{out} \times W_{out} \times C_{in} \times C_{out} \times k^2 = 2 \times C_{in} \times C_{out} \times \frac{k^2}{f^2} = 2 \times 3 \times 32 \times \frac{49}{9} = 2 \times 3 \times 8 \times 49$$

Общая формула для вычисления FLOPs

$$FLOPs = 2 \times H_{out} \times W_{out} \times C_{in} \times C_{out} \times k^2 \times \frac{S_1^2}{S_2^2} = 2 \times \frac{S_1^2}{f^2} \times B \times C_{in} \times C_{out} \times k^2 =$$

$$FLOPs(Convl 5 \times 5, S_1) = 2 \times \frac{32 \cdot 64 \cdot 25}{16} \cdot B \cdot S^2 = 2 \cdot 2 \cdot 64 \cdot 25 \cdot B \cdot S^2 = 6400 \cdot B \cdot S^2$$

$$FLOPs(Convl 3 \times 3, S_2) = 2 \times \frac{64 \cdot 128 \cdot 9}{64} \cdot B \cdot S^2 = 2304 \cdot B \cdot S^2$$

$$FLOPs(Convl 1 \times 1, 128 \rightarrow 256) = 2 \times \frac{128 \cdot 256 \cdot 1}{64} \cdot B \cdot S^2 = 1024 \cdot B \cdot S^2$$

$$FLOPs(Convl 3 \times 3, 256 \rightarrow 256) = 2 \times \frac{256 \cdot 256 \cdot 9}{256} \cdot B \cdot S^2 = 9 \cdot 4608 \cdot B \cdot S^2$$

$$FLOPs(Convl 1 \times 1, 256 \rightarrow 512) = 2 \times \frac{2 \cdot 256 \cdot 512 \cdot 1}{256} \cdot B \cdot S^2 = 1024 \cdot B \cdot S^2$$

$$FLOPs(Convl 7 \times 7, S_2, 3 \rightarrow 32) = 2 \times \frac{3 \cdot 32 \cdot 49}{9} \cdot B \cdot S^2 = 2352 \cdot B \cdot S^2$$

$$FLOPs_{свёртки} = (2352 + 6400 + 2304 + 1024 + 4608 + 1024) \cdot B \cdot S^2 = 17712 \cdot B \cdot S^2$$

$$FLOPs(Full-Linear(512, 256)) = 2 \cdot B \cdot 512 \cdot 256 = 262144 \cdot B$$

$$FLOPs(Full-Linear(256, 100)) = 2 \cdot B \cdot 256 \cdot 100 = 51200 \cdot B$$

$$FLOPs_{сум. связей} = 314344 \cdot B$$

$$FLOPs_{сум.} = 17712 \cdot B \cdot S^2 + 314344 \cdot B$$

9-та memory

Үлгілелері менен - P-4 байт, 32 P-кар-то кырамын

	C	F ²	кар-то байт ($4 \cdot C \cdot H \cdot W \cdot B = 4 \cdot B \cdot C \cdot \frac{S^2}{F^2} = 4 \cdot \frac{1}{F^2} (BS^2)$)
bias	3	1	$4 \cdot \frac{3}{1} = 12$
conv 1	32	4	$4 \cdot \frac{32}{4} = 32$
pool	32	16	$4 \cdot \frac{32}{16} = 8$
conv 2	64	16	$4 \cdot \frac{64}{16} = 16$
conv 3	128	64	$4 \cdot \frac{128}{64} = 8$
conv 4	256	64	$4 \cdot \frac{256}{64} = 16$
conv 5	256	256	$4 \cdot \frac{256}{256} = 4$
conv 6	512	256	$4 \cdot \frac{512}{256} = 8$

Үлгілелер менен Max = max(12, 32, ..., 8) = 32 байт
 Max = $\sum (12 + 32 + \dots + 8) = 144$ байт
 Mgl. = 44
 256 байт

	кар-то байт
Linear 256x256	256 B
Linear 256x100	100 B

Үлгілелер менен кырамын

үлгі	кырамын	кар-то байт
Conv 7x7x1	$3 \times 32 \times 7 \times 7$	4704 +
Conv 5x5x1	$32 \times 64 \times 5 \times 5$	51200 +
Conv 3x3x1	$64 \times 128 \times 3 \times 3$	73728 +
Conv 1x1x1	$128 \times 256 \times 1 \times 1$	32768 +
Conv 3x3x1	$256 \times 256 \times 3 \times 3$	589824 +
Conv 1x1x1	$256 \times 512 \times 1 \times 1$	131072 +
Linear 256x100	$256 \times 100 \times 100$	25700 +
Linear 512x100	$512 \times 256 \times 100$	131328 = 1039968 кырамын

MEM_STATIC = $4 \cdot 1039968 = 4159872$ байт

memory = $54 BS^2 + 4159872 + 356$ (байт)

Approx Bytes Moved

$$\text{Bytes Moved} = \sum_i (\text{read_input}_i + \text{read_weights}_i + \text{write_output}_i)$$

Layer	read_input (BS ² Saüm)	write_output (BS ² Saüm)	read_weights (Saüm)
conv	—	$4 \cdot 3 \cdot 1 = 12$	—
conv 7x7, S ₂ , 3 → 32	$4 \cdot \frac{3}{1} = 12$	$4 \cdot \frac{32}{4} = 32$	$4 \cdot 3 \cdot 32 \cdot 49 = 18816$
Max Pool 3x3, S ₂ , p ₁	$4 \cdot \frac{32}{4} = 32$	$4 \cdot \frac{32}{16} = 8$	—
conv 5x5, S ₂ , 32 → 64	$4 \cdot \frac{32}{16} = 8$	$4 \cdot \frac{64}{16} = 16$	$4 \cdot 32 \cdot 64 \cdot 25 = 204800$
conv 3x3 64 → 128	$4 \cdot \frac{64}{16} = 16$	$4 \cdot \frac{128}{64} = 8$	$4 \cdot 64 \cdot 128 \cdot 9 = 294912$
conv 1x1 128 → 256	$4 \cdot \frac{128}{64} = 8$	$4 \cdot \frac{256}{64} = 16$	$4 \cdot 128 \cdot 256 \cdot 1 = 131072$
conv 3x3 256 → 256	$4 \cdot \frac{256}{64} = 16$	$4 \cdot \frac{256}{256} = 4$	$4 \cdot 256 \cdot 256 \cdot 9 = 2359296$
conv 1x1 256 → 512	$4 \cdot \frac{256}{256} = 4$	$4 \cdot \frac{512}{256} = 8$	$4 \cdot 256 \cdot 512 \cdot 1 = 527298$

Acceleration measure clear

Layer	read_input	write_output	read_weights
512 → 256	$4 \cdot 13 \cdot 512 = 1048B$	$4 \cdot 13 \cdot 256 = 1024B$	$4 \cdot 512 \cdot 256 = 524288$
256 → 100	$4 \cdot 13 \cdot 256 = 1024B$	$4 \cdot 13 \cdot 100 = 400B$	$4 \cdot 256 \cdot 100 = 102400$

However, bytes_moved = 188BS² + 4456B + 4153872 Saüm

9-1a Latency

$$\text{Latency}(S, B) = \max(T_{\text{compute}}(S, B), T_{\text{memory}}(S, B)) + T_{\text{overhead}}$$

$$T_{\text{compute}} = \text{FLOPs}(S, B) / F_{\text{peak}}$$

$$T_{\text{memory}} = \text{Bytes Moved (S, B)} / \text{BW}$$

Пока мы выписываем и записываем в разные правые стороны уравнения, можем использовать такую формулу

$$F_{\text{peak}} = 8.1 \text{ TFLDP/s}$$

$$BW = 320 \text{ GB/s}$$

Overhead $\approx 20 \mu\text{sec}$

garthure ge GPU T4 b Kaggle

$$\text{Latency}(S, B) = \max\left(\frac{17712BS^2 + 313341B}{F_{\text{peak}}}, \frac{196BS^2 + 4159872}{B_{\text{m}}}\right) + T_{\text{over}}$$

Populze Energy

$$\text{Energy}(S, D) = E_{\text{static}} + E_{\text{memory}} + E_{\text{compute}}, \text{ etc}$$

$$E_{static} = P_{idle} \times \text{Latency}(S, D)$$

$$E_{\text{compute}} = \text{FLOPs}(S, B) \times e_{\text{flop}}$$

$$E_{memory} = \text{Bytes Moved (S, B)} \times 2 \text{ byte}$$

Паспортная мощность ТЧ составило 70 Вт, однако фактически она в 2 раза меньше. Скорость загрузки, буферизации, неиспользованной для трансляции $P_{idle} = 10 \text{ Вт}$, $P_{compute} \approx 8,6 \text{ кВт/ч}$; byte $\approx 0,21 \text{ кВт/Сек}$