Training Transformers with 4-bit Integers

Haocheng Xi, Changhao Li, Jianfei Chen, and Jun Zhu

Объясняет Чуфистов Георгий, ИТМО, 2026

Основная проблема

Обучение трансформеров - очень затратная операция с точки зрения ресурсов. Предпринимаются различные попытки снизить точность вычислений (FP16, FP8, INT8, INT4), чтобы ускорить обучение/инференс.

Sun et al., в своей работе показали способ ускорить операции за счет 4 бит, но они используют кастомный тип данных BF4, которые не совместим с современными GPU.

Цель этой статьи: показать метод обучения трансформеров, где все матричные умножения выполняются в INT4 арифметике, но при этом совместимы с существующими GPU (NVIDIA).

Проблема Forward Propagation

Существуют выбросы в активациях. Если масштаб квантования s_X большой, то теряем точность для большинства значений. Если маленький, то обрезаем выбросы, в которых может храниться важная информация.

Решение - использовать квантизатор Адамара (англ. Hadamard Quantizer, HQ): применяем блочно-диагональное преобразование Адамара к активациям и весам перед квантованием

Процедура HQ-MM:

1. Вычислить XH и H^TW^T в FP16.
2. Квантовать результат в INT4 через LSQ.
3. Умножить две INT4-матрицы (INT4 GEMM).
4. Деквантовать результат INT32 → FP16.

Проблема Backward Propagation

Градиенты имеют структурную разреженность: несколько токенов имеют огромные градиенты, остальные - почти нулевые. В то же время большие градиенты нельзя представить в INT4.

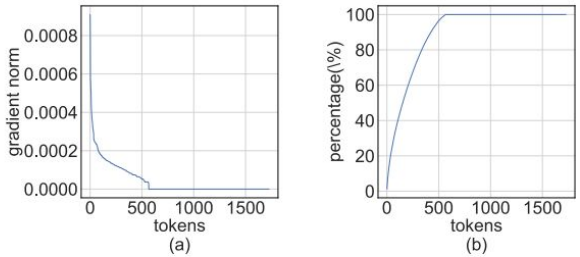


Figure 2: (a) The distribution of gradient norm along the token dimension. (b) The cumulative sum of the top X values as a percentage of the sum of all norms along the token dimension.

Проблема Backward Propagation - Bit Splitting

Решение — Bit Splitting (BS) + Leverage Score Sampling (LSS):

Bit Splitting: Разбиваем FP32-градиент на два INT4-числа:

$$\nabla_{\mathbf{Y}} \approx s_{\uparrow} \nabla_{\mathbf{Y}}^{\uparrow} + s_{\downarrow} \nabla_{\mathbf{Y}}^{\downarrow},$$

где s↑, s↓ - скаляры в формате float, ∇Y↑, ∇Y↓ - старшие 4 бита и младшие 4 бита соответственно.

Таким образом, матричные умножения выполняются в формате INT4.

Проблема Backward Propagation - Leverage Score Sampling

Leverage Score Sampling: Поскольку BS удваивает вычисления, используем коэффициент важности для отсеивания маленьких градиентов.

1. Квантовать ∇Y через BS → $\nabla Y\uparrow$, $\nabla Y\downarrow$ в INT4.
2. Вычислить leverage score* в FP16.
3. Сэмплировать маски {m_i} ~ Bernoulli(p_i).
4. Сэмплировать строки ∇Y и $\hat{X}$.
5. Вычислить два INT4 MM с сэмплированными строками.
6. Деквантовать и сложить результаты.

leverage score - важность отдельной строки (или столбца) матрицы для результата матричного умножения

В среднем получается N из 2N строк - вдвое меньше вычислений.

Результаты

Вывод: +5.5% на BERT-base, +25% на BERT-large vs LSQ+LUQ

				Baselines		4-bit training methods	
Dataset	Train type	Model	Metric name	FP	INT8	LSQ+LUQ	HQ+LSS
GLUE-dev	FT	Bert-base Bert-large	Avg Avg	$82.67_{0.24}$ $84.57_{0.42}$	$81.45_{0.13}$ $82.74_{0.24}$	$75.29_{0.52}$ $55.93_{2.47}$	$\mathbf{80.81_{0.31}}$ $\mathbf{82.25_{0.58}}$
SQUAD v1	FT	Bert-base	F1	$88.32_{0.30}$	$88.42_{0.20}$	$85.75_{0.31}$	$\mathbf{87.60_{0.25}}$
SQUAD v2	FT	Bert-base	F1	$76.04_{0.68}$	$75.63_{0.07}$	$71.02_{0.41}$	$\mathbf{74.63_{0.18}}$
Adversarial QA	FT	Bert-base	F1	$40.99_{0.38}$	$40.17_{0.58}$	$31.85_{0.30}$	$\mathbf{38.70_{0.77}}$
SWAG	FT	Bert-base	Acc	$79.84_{0.10}$	$79.18_{0.19}$	$70.79_{1.20}$	$\mathbf{77.49_{0.16}}$
CONLL	FT	Bert-base	Acc	$93.38_{0.08}$	$93.13_{0.14}$	$87.63_{0.39}$	$\mathbf{91.90_{0.48}}$
WMT	PT	Transformer-base	BLEU SacreBLEU	27.5 26.5	25.4(Ultra Low) -	27.17 -	- 25.57
CIFAR10	FT	ViT-B/32 ViT-L/32	Top1 Acc	$98.77_{0.03}$ 98.98	$98.59_{0.02}$ 98.76	$97.76_{0.10}$ 98.38	$\mathbf{98.36_{0.05}}$ **98.47**
CIFAR100	FT	ViT-B/32 ViT-L/32	Top1 Acc	$91.94_{0.11}$ 93.07	$90.99_{0.07}$ 92.2	$88.63_{0.085}$ 90.97	$\mathbf{89.78_{0.06}}$ **91.13**
ImageNet1k	FT	ViT-B/32 ViT-L/32 ViT-L/16	Top1 Acc	81.88 81.62 84.55	80.42 81.3 83.05	77.25 77.41 82.4	**79.18** **80.06** **82.61**
	PT	DeiT-small	Top1 Acc	73.1	70.95	**69.96**	69.18

Ограничения

1. Работает **только** с линейными слоями, а не со свертками
2. Не подходит для больших моделей